

Clasificación de estudios celulares del cuello cervicouterino para detección de células anormales mediante Redes Neuronales Convolucionales

Leonardo García Muñoz

2 de Agosto del 2026

1. Introducción

El examen de citología cervical que se usa para detectar cambios celulares tempranos asociados al cáncer cervicouterino es el conocido Papanicolaou, este examen es de los mejores para detectar el estado de salud de el cuello uterino cualquier paciente femenino, este mismo dice mucho del estado del paciente. La peculiaridad de este tipo de estudio, es que es a nivel celular, lo cual es perfecto para realizar un análisis a profundidad del mismo estudio, de una manera más automatizada, con el fin de buscar patrones y buscando una manera de realizar una detección temprana de comportamientos o padecimientos anormales en las células del cuello uterino de los pacientes.

Por lo que en el siguiente reporte construiremos una Red Neuronal Convolucional (CNN) con el fin de que esta misma reconozca patrones anormales en las células de los pacientes, con el fin de detectar de manera temprana cualquier posible situación de riesgo de salud en los pacientes.

2. Metodología

Para este análisis se utilizó el dataset SIPaKMeD, el cual contiene imágenes de células cervicales obtenidas de exámenes de Papanicolaou, donde se tomaron fragmentos de la muestra del Papanicolaou pero vistos a nivel microscopio, donde aparecen varias células juntas clasificadas originalmente en 5 categorías según su forma. Para simplificar el problema a una clasificación menos compleja, esas 5 categorías se agruparon en dos clases: normal y anormal.

Cuadro 1: Categorías celulares del conjunto de datos SI-PaKMeD

Categoría	Grupo médico	Qué es
Superficial-Intermedia	Normal	Células maduras, la mayoría de lo que se observa en una prueba de Papanicolaou normal.
Parabasal	Normal	Células más jóvenes o inmaduras, también consideradas sanas.
Metaplastic	Anormal	Cambio celular "normal"; no corresponde a cáncer pues es benigno, aunque puede requerir seguimiento clínico pues no es normal.
Koilocytotic	Anormal	Cambios característicos de infección por el Virus del Papiloma Humano (VPH).
Dyskeratotic	Anormal	Queratinización anómala asociada con lesiones precancerosas o cancerosas.

Las imágenes de cada clase se repartieron en tres conjuntos: 70 % para entrenamiento, 15 % para validación y 15 % para prueba, manteniendo esa proporción por separado en cada clase. Solo al conjunto de entrenamiento se le aplicó aumento de datos con rotaciones aleatorias, zoom y volteos horizontales/verticales, con el fin de que el modelo no memorice la orientación exacta de las imágenes y generalice mejor ante variaciones que no cambian el diagnóstico.




Figura 1: Imagen aplicando rotaciones aleatorias como ejemplo de lo introducido en el train set




Figura 2: Ejemplos de las imágenes que contiene el dataset

Para la clasificación se usó transfer learning: en lugar de entrenar una red neuronal convolucional desde cero, se partió de MobileNetV2, una red ya entrenada

previamente con millones de imágenes generales, y se le agregaron capas propias encima (una capa densa con activación ReLU, dropout para apagar ciertas neuronas y así evitar un sobreajuste, y una capa final con activación sigmoide que da la probabilidad de que la célula sea anormal). Esto aprovecha que MobileNetV2 ya sabe reconocer patrones visuales básicos (bordes, texturas, formas), y solo hace falta enseñarle a combinarlos para este tipo de imágenes, lo cual requiere mucho menos potencia computacional, así como tiempo, que entrenar una red neuronal completa desde cero, y más con la complejidad de las imágenes que tenemos.




Figura 3: Imagen ilustrativa de la función ReLU (Rectified Linear Unit)




Figura 4: Imagen ilustrativa de la función Sigmoide




Figura 5: Imagen ilustrativa de que hace un dropout en la red

El entrenamiento se hizo en dos fases. En la primera, se mantuvieron congelados los pesos de MobileNetV2 y solo se entrenaron las capas nuevas agregadas, durante

15 épocas.

En la segunda fase (aquí aplicamos un fine-tuning), se descongelaron las últimas 30 capas de MobileNetV2 y se continuó entrenando todo en conjunto, con una tasa de aprendizaje mucho más baja para hacer que la red ajuste de manera más lenta los pesos que ya aprendió, sin destruir el conocimiento adquirido, esto durante otras 15 épocas, esto con la finalidad de que el modelo ajuste ligeramente su conocimiento general hacia las particularidades específicas de las imágenes de citología cervical, sin perder de golpe los conocimientos básicos de patrones que ya sabía el MobileNetV2.




Figura 6: Imagen ilustrativa de que tiene MobileNetV2 en su interior (su respectiva llave)

Finalmente, el desempeño del modelo se evaluó sobre el conjunto de prueba (que el modelo nunca vio durante el entrenamiento, esto es súper importante) mediante una matriz de confusión, métrica de accuracy y una revisión visual de ejemplos individuales donde se compara la predicción del modelo contra la etiqueta real (un back-testing en pocas palabras) para analizar los errores.

3. Resultados

El modelo final alcanzó un accuracy de 87.6 % sobre el conjunto de prueba, después de las dos fases de entrenamiento (base congelada + fine-tuning).

Con el mapa de calor podemos apreciar que las 96 células realmente anormales, el modelo identificó correctamente 81, pero clasificó 15 como normales. En cambio, de las 33 células realmente normales, solo 1 se confundió con anormal. Esto muestra que el modelo es bastante confiable cuando dice "anormal" (casi nunca se equivoca en falsos positivos), pero le cuesta más detectar todos los casos anormales reales, dejando pasar algunos como si fueran normales, lo cual sí puede llegar a ser peligroso.




Figura 7: Mapa de Calor

Ahora, de manera más visual, mostrando 8 ejemplos tomados al azar del conjunto de prueba, comparando la etiqueta real contra la predicción del modelo. El modelo acertó en 6 y falló en 2, proporción que sí es consistente con el accuracy obtenido. Es interesante notar que los dos errores no parecen deberse a mala calidad, sino que corresponden a casos donde visualmente las células podrían compartir características con ambas categorías, lo que sugiere que el error del modelo no es aleatorio, sino que se concentra en los casos más complejos o específicos, donde incluso la clasificación manual podría ser más difícil de definir con seguridad sin tener un especialista experimentado.




Figura 8: Ejemplos visuales de Backtest




Figura 9: Ejemplos visuales de Backtest

4. Conclusiones

Con los resultados obtenidos podemos concluir que el modelo es muy eficiente al momento de determinar si un paciente o imagen se le podría clasificar en el comportamiento anormal, mientras que al momento de detectar los comportamientos celulares normales, tiende a tener más problemas en ciertos casos, lo cual no hace 100 % confiable al modelo para diagnósticos sin un profesional de la salud con su pertinente experiencia en citología y ginecología, pero el mismo es bastante bueno en comportamiento general.

Adicionalmente de darle el reconocimiento al entrenamiento más eficiente que se realizó mediante la utilización de MobileNetV2, así como la precisión que llega a tener el modelo respecto a algoritmos como HoughCircles, pues la red es lo suficientemente capaz de aprender patrones de comportamiento en las células y clasificarlos de una manera bastante buena, aunque no perfecta.